

Proiect 6 — Meme-uri românești: OCR → normalizare → clasificare (text-only vs multimodal)

1. Descriere

Proiectul dezvoltă un pipeline multimodal pentru meme-uri în limba română: se extrage textul din imagine (OCR), se normalizează (corecții OCR + diacritizare), apoi se realizează clasificare (temă/sentiment/propagandă). Componenta centrală este evaluarea experimentală: cât pierde OCR, cât se recuperează prin normalizare și cât câștigă un model multimodal față de unul text-only [1], [2].

2. Resurse necesare și surse de date (download)

RoMEMES / RoMemes: corpus multimodal românesc disponibil pe Zenodo, însoțit de articol descriptiv [1], [2].

Subset GOLD OCR: 500–1000 imagini cu transcriere manuală a textului pentru a evalua direct CER/WER.

(Opțional) set de validare pentru propagandă: selectarea unui subset de meme-uri și adnotarea cu inventar de etichete compatibil cu Proiectul 3.

3. Metodă

- 3.1. OCR: se compară cel puțin două sisteme (Tesseract și EasyOCR) pentru a cuantifica impactul calității OCR [3], [4].
- 3.2. Preprocesare imagini: redimensionare, binarizare, denoise (OpenCV) pentru a îmbunătăți OCR.
- 3.3. Normalizare text: corecții tipice OCR + diacritizare (integrare cu Proiectul 1, dacă este disponibil).
- 3.4. Clasificare:
 - 3.4.1. Text-only: Transformer pe textul OCR normalizat.
 - 3.4.2. Multimodal: encodare imagine + text, inspirat de CLIP (sau o arhitectură similară) [5].

- 3.5. Ablații obligatorii: OCR brut vs OCR+normalizare vs OCR + normalizare + diacritizare; text-only vs multimodal.

4. Evaluare

- 4.1. OCR: CER/WER pe subsetul transcris.
- 4.2. Clasificare: macro-F1 (clase dezechilibrate) și raportare pe subtipuri.
- 4.3. Analize: corelația între scorul OCR și performanța clasificării.

5. Tehnologii

- 5.1. OpenCV; Tesseract/EasyOCR; PyTorch; Transformers; (opțional) CLIP-like.
- 5.2. Demo: Streamlit/FastAPI.

6. Livrabile

- 6.1. Raport comparativ OCR (Tesseract vs EasyOCR) cu exemple.
- 6.2. Model text-only + model multimodal + comparație.
- 6.3. Demo: încărcare imagine → text extras + predicții + evidențiere.

Bibliografie

1. RoMEMES dataset (Zenodo record). Link: <https://zenodo.org/records/13120216>
2. Păiș, V. et al. (2024). RoMemes: A multimodal meme corpus for the Romanian language. arXiv. Link: <https://arxiv.org/abs/2410.15497>
3. Tesseract OCR repository. Link: <https://github.com/tesseract-ocr/tesseract>
4. EasyOCR repository. Link: <https://github.com/JaidedAI/EasyOCR>
5. Radford, A. et al. (2021). Learning Transferable Visual Models From Natural Language Supervision (CLIP). arXiv. Link: <https://arxiv.org/abs/2103.00020>